

Multivariate Outlier Detection

基于鲁棒统计 (MCD)、结构降维 (Robust PCA) 及机器学习 (Isolation Forest) 的多种多元异常值判定方法，以提高异常判定结果的稳健性与可信度。

1. 不同方法关注异常的不同方面:

1.1 MCD: “这个观测点在统计意义上是否偏离总体中心?”;

1.2 PCA / Robust PCA: “这个观测点是否破坏了数据的主要结构模式?”

1.3 Isolation Forest: “这个观测点在样本空间中是否容易被孤立?”

2. 在实际数据分析与教学中:

2.1 只用 MCD: 可能漏掉“结构异常但不远离中心”的点;

2.2 只用 PCA: 阈值解释困难, 统计意义较弱;

2.3 只用 Isolation Forest: 缺乏可检验性, 难以学术表述;

多方法一致判定的异常点, 其可信度通常更高, 这是当前学术界的普遍共识。

3. 在多元异常值判定的教学与应用中, 推荐采用以下分层策略:

3.1 MCD 作为统计基准方法, 提供权威且可解释的异常判定;

3.2 Robust PCA 用于揭示异常点的结构来源, 并辅助可视化解释;

3.3 Isolation Forest 作为补充探索方法, 用于发现潜在的非线性或复杂异常。

| 维度 | MCD (Robust Mahalanobis) | PCA / Robust PCA | Isolation Forest |
|-----------|-----------------------------------|--------------------------------------|-----------------------|
| 方法学本质 | 鲁棒协方差估计的统计方法 | 基于低维结构的几何方法 | 基于随机划分的机器学习方法 |
| 异常的定义 | 偏离总体中心的统计异常 | 偏离主成分结构的几何异常 | 在样本空间中易被孤立的异常 |
| 对数据分布的要求 | 近似多元正态 (弱) | 无严格分布假设 | 完全无分布假设 |
| 判定依据 | 鲁棒 MD ² 与 χ^2 分位数 | Score Distance / Orthogonal Distance | Isolation score (相对值) |
| 是否有明确阈值 | 是 (χ^2 cutoff) | 部分 (经验或文献建议) | 否 (排序或比例) |
| 是否参数法 | 是 | 半参数 | 否 |
| 对异常值的鲁棒性 | 高 (设计初衷) | 高 (使用 Robust PCA 时) | 高 |
| 对高维数据的适应性 | 一般 (p 不能接近 n) | 较好 | 很好 |
| 是否需要标准化 | 必须 | 必须 | 强烈建议 |
| 对变量相关性的依赖 | 强 (协方差结构) | 强 (相关性越强越有效) | 弱 |
| 可解释性 | 很强 (统计意义清晰) | 强 (结构与方向可解释) | 较弱 (算法黑箱) |
| 结果稳定性 | 高 | 中等 (依赖 PC 数) | 较低 (随机性) |
| 主要优势 | 权威、可检验、易解释 | 可视化好、揭示结构异常 | 捕捉复杂非线性异常 |
| 主要局限 | 不适合极高维或多峰分布 | 阈值不统一、解释需经验 | 无显著性、解释困难 |
| 典型误用风险 | 忽略标准化或样本量不足 | 将 PCA 当“异常值专用工具” | 将 score 当统计显著性 |
| 教学使用建议 | 作为基准与主方法 | 作为结构补充方法 | 作为探索与验证方法 |